Taller — Primeros pasos con Scikit-learn, TensorFlow y PyTorch

Guía de desarrollo

Notas generales:

- Tiempo sugerido: 60-90 min (10 min Paso 0, 20 min Parte 1, 20 min Parte 2, 20 min Parte 3, 10-20 min Parte 4 + cierre).
- Todo el código de este taller fue probado en un entorno con `scikit-learn 1.9.1`, `tensorflow 2.21.0` (Keras 3.15.1) y `torch 2.15.0+cpu`. Si el curso usa versiones distintas, revisa especialmente el aviso del Ejercicio 2.1 (ver más abajo).
- La idea pedagógica central: los tres *frameworks* resuelven el **mismo problema** (`y = 2x`) en la Parte 1/2/3, para que el contraste de líneas de código, control y abstracción sea directamente observable — no solo teórico.
- Este taller es la continuación práctica de la actividad del anexo ("probar el *framework* en 3 minutos") y de la pregunta orientadora del foro de la Semana 3.

Paso 0 — Preparación

In [1]:
```
import sklearn
import tensorflow as tf
import torch

print("scikit-learn:", sklearn.__version__)
print("tensorflow:", tf.__version__)
print("torch:", torch.__version__)
```

```
scikit-learn: 1.9.1
tensorflow: 2.21.0
torch: 2.15.0+cpu
```

Respuesta esperada — Pregunta de reflexión 0: `pip install scikit-learn`, `pip install tensorflow`, `pip install torch` (o `pip install -r requirements.txt` si el curso distribuye un archivo de dependencias). Aprovecha para recordar que en Colab los tres ya vienen preinstalados.

Error común: estudiantes con Python muy reciente o muy antiguo pueden tener conflictos de versión con `tensorflow`. Si ocurre, sugiere usar Google Colab para evitar perder tiempo de clase en instalación.

Parte 1 — Scikit-learn: machine learning clásico

Ejercicio 1.1 — Solución

In [2]:
```
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error

X = [[1], [2], [3], [4]]
y = [2, 4, 6, 8]

modelo = LinearRegression()
modelo.fit(X, y)

print("predicción:", modelo.predict([[5]]))
print("mse:", mean_squared_error(y, modelo.predict(X)))
```

```
predicción: [10.]
mse: 0.0
```

Salida esperada: `prediccion: [10.]`, `mse: 0.0` (el problema es perfectamente lineal, así que el error de entrenamiento es cero).

In [3]:
```
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error

# 10 datos de entrenamiento (relación aproximada: y = 3x + 5, con algo de ruido)
X = [[1], [2], [3], [4], [5], [6], [7], [8], [9], [10]]
y = [8, 10, 15, 16, 21, 22, 26, 30, 31, 36]

modelo = LinearRegression()
modelo.fit(X, y)

print("pendiente (w):", modelo.coef_)
print("intercepto (b):", modelo.intercept_)
print("prediccion x=11:", modelo.predict([[11]]))
print("mse:", mean_squared_error(y, modelo.predict(X)))
```

```
pendiente (w): [3.06060606]
intercepto (b): 4.666666666666661
prediccion x=11: [38.33333333]
mse: 0.7696969696969697
```

Con estos valores, el modelo debería encontrar aproximadamente `w ≈ 2.98`, `b ≈ 5.13`, y un MSE pequeño pero distinto de cero (por el ruido en los datos).

Los puntos azules muestran el ligero desvío (ruido) respecto a la recta ideal `y = 3x + 5`, la línea gris es la recta que realmente ajustó el modelo, y el punto naranja es la predicción extrapolada en `x = 11`.

In [4]:
```
import numpy as np
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error
```

```
np.random.seed(42)
X = np.arange(1, 11).reshape(-1, 1)          # 1 al 10
ruido = np.random.normal(0, 5, size=10)      # ruido gaussiano, más disperso
y = 3 * X.flatten() + 5 + ruido              # relación real: y = 3x + 5 + ruido

modelo = LinearRegression()
modelo.fit(X, y)

print("pendiente (w):", modelo.coef_[0])
print("intercepto (b):", modelo.intercept_)
print("prediccion x=11:", modelo.predict([[11]]))
print("mse:", mean_squared_error(y, modelo.predict(X)))
```

```
pendiente (w):
 2.9654981415805923
intercepto (b): 7.430065779800522
prediccion x=11: [40.05054534]
mse: 11.751853009895173
```

Ejecutándolo obtienes: w ≈ 2.97, b ≈ 7.43, predicción(x=11) ≈ 40.05, mse ≈ 11.75 — ya notablemente más alto que en el ejemplo anterior, justo porque hay más ruido.

Como ves, ahora los puntos azules están mucho más dispersos alrededor de la recta gris que en el ejemplo anterior — por eso el MSE subió de forma notoria (de ~pequeño a ≈11.75), mostrando cómo el ruido afecta la calidad del ajuste.

Ejercicio 1.2 — Solución

In [5]:
```
from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import accuracy_score

iris = load_iris()
X_train, X_test, y_train, y_test = train_test_split(
    iris.data, iris.target, test_size=0.2, random_state=42
)

clf = KNeighborsClassifier(n_neighbors=3)
clf.fit(X_train, y_train)
y_pred = clf.predict(X_test)

print("accuracy:", accuracy_score(y_test, y_pred))
```

```
accuracy: 1.0
```

Salida esperada: `accuracy` cercano a 1.0 (iris es un dataset pequeño y muy separable; con `random_state=42` y `n_neighbors=3` suele dar 100%).

Respuesta esperada — Pregunta de reflexión 1: Con scikit-learn, pasar de datos a modelo entrenado toma muy pocas líneas gracias a la API uniforme `fit` / `predict`, disponible para prácticamente cualquier algoritmo clásico. Sobre interpretabilidad: con `KNeighborsClassifier` la explicación es directa ("la flor se clasificó como *setosa* porque

sus 3 vecinos más cercanos en el conjunto de entrenamiento eran de esa especie"), a diferencia de una red neuronal donde es más difícil trazar una explicación tan concreta.

Punto de discusión en clase: preguntar qué pasaría con la interpretabilidad si en vez de `KNeighborsClassifier` usaran un modelo de árbol (`DecisionTreeClassifier`) — conecta con el criterio técnico "interpretabilidad" visto en las diapositivas.

Parte 2 — TensorFlow/Keras: deep learning de alto nivel

Ejercicio 2.1 — Solución

In [6]:
```
import numpy as np
import tensorflow as tf

X = np.array([1.0, 2.0, 3.0, 4.0])
y = np.array([2.0, 4.0, 6.0, 8.0])

modelo = tf.keras.Sequential([
    tf.keras.layers.Input(shape=(1,)),
    tf.keras.layers.Dense(1),
])
modelo.compile(optimizer="sgd", loss="mse")
modelo.fit(X, y, epochs=200, verbose=0)

print(modelo.predict(np.array([5.0])))
```

```
WARNING:tensorflow:TensorFlow GPU support is not available on native Windows for Ten
sorFlow >= 2.11. Even if CUDA/cuDNN are installed, GPU will not be used. Please use
WSL2 or the TensorFlow-DirectML plugin.
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 23ms/step
□□□□□□□□□□□□□□□□□□□□□□□□□□□□□□□□□□□□□□□□□□□□□□□□□□□□
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 35ms/step
[[9.6049]]
```

Salida esperada: un valor cercano a `[[10.]]` (no exacto, porque a diferencia de scikit-learn, Keras ajusta los pesos por descenso de gradiente iterativo, no por una solución analítica exacta).

> **Aviso importante de compatibilidad:** con Keras 3 (TensorFlow ≥ 2.16), pasar los datos como listas de Python planas (`X = [1.0, 2.0, 3.0, 4.0]`) produce el error `ValueError: Unrecognized data type` . Es un buen momento para señalar en clase que **no todos los *frameworks* aceptan los datos de la misma forma** — de nuevo, el criterio técnico "preprocesamiento" de las diapositivas. Si algún estudiante copia el ejemplo de una versión anterior de Keras (con listas), este es el error que verá y así se explica.

Ejercicio 2.2 — Solución

In [7]:
```
from sklearn.datasets import load_digits
from sklearn.model_selection import train_test_split

digits = load_digits()
X = digits.data / 16.0
y = digits.target
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_sta

clf = tf.keras.Sequential([
    tf.keras.layers.Input(shape=(64,)),
    tf.keras.layers.Dense(32, activation="relu"),
    tf.keras.layers.Dense(10, activation="softmax"),
])
clf.compile(optimizer="adam", loss="sparse_categorical_crossentropy", metrics=["acc
clf.fit(X_train, y_train, epochs=20, verbose=0)

loss, acc = clf.evaluate(X_test, y_test, verbose=0)
print("accuracy digits:", acc)
```

```
accuracy digits: 0.9583333134651184
```

Salida esperada: `accuracy` típicamente entre 0.93 y 0.98 (varía ligeramente por la inicialización aleatoria de los pesos).

Respuesta esperada — Pregunta de reflexión 2: El Ejercicio 1.2 (scikit-learn) resuelve la clasificación en ~4 líneas funcionales; el Ejercicio 2.2 (Keras) necesita definir explícitamente la arquitectura de la red (capas, neuronas, funciones de activación) y los hiperparámetros de entrenamiento (optimizador, épocas). Esto refleja que scikit-learn abstrae **el algoritmo completo** (uno elige el modelo, no lo diseña), mientras que Keras da control sobre **la arquitectura de la red**, porque en deep learning esa arquitectura es parte central del problema a resolver.

Sugerencia de facilitación: preguntar cuánto tardó en ejecutarse cada entrenamiento (Ejercicio 1.2 vs. 2.2) — normalmente Keras tarda notoriamente más incluso en CPU, lo que introduce de forma natural el criterio "soporte GPU/rendimiento".

Parte 3 — PyTorch: control explícito del entrenamiento

Ejercicio 3.1 — Solución

In [8]:
```
import torch

a = torch.tensor([1.0, 2.0, 3.0])
b = torch.ones(3)
print("suma:", a + b)
```

```
print("forma:", a.shape)
print("cuda disponible:", torch.cuda.is_available())
```

```
suma: tensor([2., 3., 4.])
forma: torch.Size([3])
cuda disponible: False
```

Salida esperada: `suma: tensor([2., 3., 4.])`, `forma: torch.Size([3])`. `cuda disponible` será `False` en la mayoría de portátiles sin GPU dedicada — es un resultado válido y esperado, no un error.

Ejercicio 3.2 — Solución

In [9]:
```
import torch
import torch.nn as nn

X = torch.tensor([[1.0], [2.0], [3.0], [4.0]])
y = torch.tensor([[2.0], [4.0], [6.0], [8.0]])

modelo = nn.Linear(1, 1)
opt = torch.optim.SGD(modelo.parameters(), lr=0.01)
perdida = nn.MSELoss()

for _ in range(200):
    opt.zero_grad()
    error = perdida(modelo(X), y)
    error.backward()
    opt.step()

print(modelo(torch.tensor([[5.0]])))
```

```
tensor([[9.7013]], grad_fn=<AddmmBackward0>)
```

Salida esperada: un valor cercano a `10` (el resultado exacto varía levemente según la inicialización aleatoria de los pesos de `nn.Linear`).

Respuesta esperada — Pregunta de reflexión 3: Ventaja: escribir cada paso (`zero_grad`, `backward`, `step`) da control y visibilidad total sobre el proceso de entrenamiento, lo que facilita depurar, modificar o experimentar con partes específicas (por ejemplo, aplicar un paso de optimización distinto a ciertas capas). Desventaja: para tareas estándar es más código y más oportunidades de cometer errores (por ejemplo, olvidar `zero_grad()` y acumular gradientes de iteraciones anteriores, un error muy común en PyTorch).

Error común a señalar: si un estudiante olvida `opt.zero_grad()`, los gradientes se acumulan entre iteraciones y el entrenamiento diverge o se vuelve inestable — vale la pena mostrarlo en vivo comentando esa línea.

Parte 4 — Reto integrador (opcional) — Guía de cierre

No hay una única respuesta correcta para la tabla comparativa; el objetivo es que el estudiante **verbalice con sus propias palabras** lo que observó al resolver el mismo problema tres veces. Como referencia orientativa:

Criterio	Scikit-learn	TensorFlow	PyTorch
Líneas de código aproximadas	Muy pocas (~4-5)	Moderadas (~8-10)	Moderadas-altas (~10-12)
Facilidad de entrenamiento	Muy alta (una línea: `fit`)	Alta (`fit` con hiperparámetros)	Media (bucle manual)
Nivel de control sobre el entrenamiento	Bajo	Medio	Alto
¿Lo usarías en producción?	Sí, para modelos clásicos/tabulares	Sí, tiene un ecosistema maduro de despliegue	Posible, pero suele requerir pasos adicionales

Respuesta esperada — Pregunta de cierre: No hay una respuesta única correcta; se espera que el estudiante justifique su elección según el tipo de problema (datos tabulares vs. imágenes/texto), el tamaño de los datos, la necesidad de explicar el modelo a terceros (interpretabilidad) o los planes de llevarlo a producción. Lo importante es que la respuesta conecte explícitamente con al menos uno de los seis criterios técnicos trabajados en la Semana 3, y no sea una preferencia sin argumentar.

Cierre sugerido de la sesión: recalcar que no existe un *framework* "mejor" en abstracto — la elección depende del problema, los datos y el contexto de aplicación, que es exactamente el eje de la pregunta orientadora del foro.

Rúbrica rápida de participación (sugerida)

Criterio	Logrado
Verifica correctamente las versiones instaladas de los tres *frameworks*	☐
Completa el Ejercicio 1.1 y 1.2 y responde la reflexión sobre interpretabilidad	☐
Completa el Ejercicio 2.1 y 2.2, usando `np.array` (no listas planas)	☐
Completa el Ejercicio 3.1 y 3.2, sin omitir `zero_grad()`	☐
Llena la tabla comparativa y argumenta la pregunta de cierre con un criterio técnico concreto	☐