# Taller: Estadística Inferencial — Puente hacia Regresión Lineal (Semanas 7-8)

**Fundamentos para IA Versión docente — solución completa, paso a paso, con código**

Este *notebook* resuelve en detalle los 6 ejercicios de `Taller_01_Estadistica_inferencial.md`, mostrando para cada uno:

1. La **fórmula matemática** completa.
2. El **cálculo manual**, paso a paso, con los números reales de `StudentsPerformance.csv`.
3. La **verificación** con `scipy` / `statsmodels` (deben coincidir exactamente con el cálculo manual).
4. La **interpretación** en palabras simples.

El objetivo es consolidar el vocabulario de inferencia estadística (comparación de grupos, correlación, p-value, tamaño del efecto) que se necesita para construir modelos de regresión lineal en las Semanas 7 y 8.

## Configuración inicial

In [1]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from scipy import stats

sns.set_theme(style="whitegrid")
pd.set_option("display.max_columns", None)

df = pd.read_csv("StudentsPerformance.csv")
alpha = 0.05
print(f"Dataset: {df.shape[0]} estudiantes, {df.shape[1]} columnas.")
df.head()
```

```
Dataset: 1000 estudiantes, 8 columnas.
```

Out[1]:

| | gender | race/ethnicity | parental level of education | lunch | test preparation course | math score | reading score | writing score |
|---|---|---|---|---|---|---|---|---|
| **0** | female | group B | bachelor's degree | standard | none | 72 | 72 | 74 |
| **1** | female | group C | some college | standard | completed | 69 | 90 | 88 |
| **2** | female | group B | master's degree | standard | none | 90 | 95 | 93 |
| **3** | male | group A | associate's degree | free/reduced | none | 47 | 57 | 44 |
| **4** | male | group C | some college | standard | none | 76 | 78 | 75 |

---

# Ejercicio 1 — Repaso: comparar dos grupos

**Situación:** ¿el puntaje de escritura ( `writing score` ) difiere entre hombres y mujeres?

- **H0:** μ(hombres) = μ(mujeres)
- **H1:** μ(hombres) ≠ μ(mujeres)

In [2]:
```
hombres_w = df.loc[df["gender"] == "male", "writing score"]
mujeres_w = df.loc[df["gender"] == "female", "writing score"]

n1, n2 = len(hombres_w), len(mujeres_w)
m1, m2 = hombres_w.mean(), mujeres_w.mean()
s1, s2 = hombres_w.std(ddof=1), mujeres_w.std(ddof=1)

print(f"Hombres: n={n1}, media={m1:.4f}, desv.est={s1:.4f}")
print(f"Mujeres: n={n2}, media={m2:.4f}, desv.est={s2:.4f}")
```

```
Hombres: n=482, media=63.3112, desv.est=14.1138
Mujeres: n=518, media=72.4672, desv.est=14.8448
```

## Paso 1a — Validar el supuesto de homogeneidad de varianzas (Levene)

Levene centra cada grupo en su **mediana**, mide qué tan lejos se aleja cada dato de esa mediana ($Z_{ij} = |X_{ij} - \tilde{X}_i|$), y compara esos alejamientos entre grupos con una fórmula tipo ANOVA:

$$W = \frac{N-k}{k-1} \cdot \frac{\sum_i n_i (\bar{Z}_{i\cdot} - \bar{Z}_{\cdot\cdot})^2}{\sum_i \sum_j (Z_{ij} - \bar{Z}_{i\cdot})^2}$$

In [3]:
```python
def levene_manual(g1, g2):
    Ns = [len(g1), len(g2)]
    N, k = sum(Ns), 2
    centros = [np.median(g1), np.median(g2)]
    Z = [np.abs(np.asarray(g) - c) for g, c in zip([g1, g2], centros)]
    Zbar_i = [z.mean() for z in Z]
    Zbar = np.concatenate(Z).mean()
    numerador = (N - k) * sum(n * (zi - Zbar) ** 2 for n, zi in zip(Ns, Zbar_i))
    denominador = (k - 1) * sum(((z - zi) ** 2).sum() for z, zi in zip(Z, Zbar_i))
    W = numerador / denominador
    p = stats.f.sf(W, k - 1, N - k)
    return W, p

W_manual, p_levene_manual = levene_manual(hombres_w, mujeres_w)
print(f"Levene manual   -> W={W_manual:.6f}, p-value={p_levene_manual:.6f}")

levene_scipy = stats.levene(hombres_w, mujeres_w)
print(f"Levene (scipy)  -> W={levene_scipy.statistic:.6f}, p-value={levene_scipy.pvalue:.6f}")
```

```
Levene manual   -> W=0.006939, p-value=0.933627
Levene (scipy)  -> W=0.006939, p-value=0.933627
```

**Interpretación:** p ≥ 0.05 → **no se rechaza** la homogeneidad de varianzas. Los dos grupos tienen una dispersión (variedad) prácticamente idéntica, lo que respalda usar la prueba t **clásica** (varianzas combinadas), en vez de la variante de Welch.

## Paso 1b — Aplicar la prueba t (varianza combinada)

$$s_p^2 = \frac{(n_1-1)s_1^2 + (n_2-1)s_2^2}{n_1+n_2-2} \qquad SE = \sqrt{s_p^2\left(\frac{1}{n_1}+\frac{1}{n_2}\right)}$$

$$t = \frac{\bar{x}_1 - \bar{x}_2}{SE} \qquad df = n_1 + n_2 - 2$$

In [4]:
```
sp2 = ((n1 - 1) * s1**2 + (n2 - 1) * s2**2) / (n1 + n2 - 2)
se = np.sqrt(sp2 * (1 / n1 + 1 / n2))
t_manual = (m1 - m2) / se
df_t = n1 + n2 - 2
p_t_manual = 2 * stats.t.sf(abs(t_manual), df_t)

print(f"sp^2={sp2:.4f}  SE={se:.4f}")
print(f"t manual -> t={t_manual:.4f}, df={df_t}, p-value={p_t_manual:.4g}")

t_scipy = stats.ttest_ind(hombres_w, mujeres_w, equal_var=True)
print(f"t (scipy) -> t={t_scipy.statistic:.4f}, df={t_scipy.df:.0f}, p-value={t_scipy.pvalue:.4g}")
```

```
sp^2=210.1666  SE=0.9175
t manual -> t=-9.9796, df=998, p-value=2.02e-22
t (scipy) -> t=-9.9796, df=998, p-value=2.02e-22
```

## Paso 1c — ¿Cuánta diferencia hay? (tamaño del efecto)

El p-value dice **si** hay diferencia; no dice **cuánta**. Eso se responde con una simple resta — y, para comparar con otros estudios, con el tamaño del efecto estandarizado (Cohen's d).

In [5]:
```
diferencia = m2 - m1
cohen_d = diferencia / np.sqrt(sp2)

print(f"Diferencia de medias (mujeres - hombres): {diferencia:.2f} puntos")
print(f"Cohen's d: {cohen_d:.3f}")

decision = "se rechaza H0" if t_scipy.pvalue < alpha else "no se rechaza H0"
print(f"\nDecisión (alpha=0.05): {decision}")
print("Conclusión: hay evidencia estadísticamente muy fuerte de que el puntaje de escritura difiere "
      f"entre géneros; las mujeres promedian ~{diferencia:.1f} puntos más (Cohen's d={cohen_d:.2f}, "
      "un efecto mediano-grande).")
```

```
Diferencia de medias (mujeres - hombres): 9.16 puntos
Cohen's d: 0.632

Decisión (alpha=0.05): se rechaza H0
Conclusión: hay evidencia estadísticamente muy fuerte de que el puntaje de escritura difiere entre géneros; las mujeres promedian ~9.2 puntos más (Cohen's d=0.63, un efecto mediano-grande).
```

---

# Ejercicio 2 — Probar si una correlación es significativa (puente a regresión)

**Situación:** ¿existe correlación entre `math score` y `reading score`?

- **H0:** ρ = 0 (no hay correlación real en la población)
- **H1:** ρ ≠ 0

## Fórmula de Pearson r y su prueba de significancia

$$r = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2 \sum_i (y_i - \bar{y})^2}} \qquad t = r\sqrt{\frac{n-2}{1-r^2}},\ df = n-2$$

In [6]:
```
x = df["math score"].values
y = df["reading score"].values
n = len(x)
xbar, ybar = x.mean(), y.mean()

r_manual = np.sum((x - xbar) * (y - ybar)) / np.sqrt(np.sum((x - xbar) ** 2) * np.sum((y - ybar) ** 2))
t_r = r_manual * np.sqrt((n - 2) / (1 - r_manual**2))
p_r_manual = 2 * stats.t.sf(abs(t_r), n - 2)

print(f"r manual -> r={r_manual:.4f}, t={t_r:.2f}, df={n-2}, p-value={p_r_manual:.4g}")

r_scipy = stats.pearsonr(x, y)
print(f"pearsonr (scipy) -> r={r_scipy.statistic:.4f}, p-value={r_scipy.pvalue:.4g}")
```

```
r manual -> r=0.8176, t=44.86, df=998, p-value=1.788e-241
pearsonr (scipy) -> r=0.8176, p-value=1.788e-241
```

**Interpretación:** r = 0.818 es una correlación **fuerte y positiva**. El p-value es prácticamente cero → **se rechaza H0**: la relación entre `math score` y `reading score` es real, no un artefacto de la muestra.

---

## Ejercicio 3 — Qué SÍ y qué NO te dice el coeficiente de correlación

**Situación:** correlación entre `reading score` y `writing score`.

In [7]:
```
r_rw = df["reading score"].corr(df["writing score"])
print(f"Correlación reading vs. writing: r = {r_rw:.4f}")

fig, ax = plt.subplots(figsize=(6, 5))
sns.scatterplot(data=df, x="reading score", y="writing score", alpha=0.4, ax=ax)
ax.set_title(f"reading score vs. writing score (r = {r_rw:.3f})")
plt.tight_layout()
plt.show()
```

```
Correlación reading vs. writing: r = 0.9546
```




**a)** r = 0.955 es una correlación **fuerte y positiva** (muy cercana a 1).

**b) No.** Correlación no implica causalidad: podría deberse a un factor común (habilidad verbal general, hábitos de estudio) sin que una habilidad "cause" directamente a la otra.

**c) No es correcto** decir "por cada punto que sube reading, writing sube 0.955 puntos". Eso es lo que mide la **pendiente** de una recta de regresión (Ejercicio 4), no la correlación — r es adimensional (mide fuerza y dirección), la pendiente sí tiene unidades (puntos de writing por punto de reading). Confundir ambas es uno de los errores más comunes al pasar de correlación a regresión.

---

# Ejercicio 4 — Interpretar una recta de regresión lineal simple

**Situación:** se ajusta una recta para predecir `writing score` a partir de `reading score`.

## Fórmula de la pendiente y el intercepto (mínimos cuadrados)

$$m = \frac{S_{xy}}{S_{xx}} = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2} \qquad b = \bar{y} - m\bar{x}$$

In [8]:
```
x_r = df["reading score"].values
y_w = df["writing score"].values
xbar_r, ybar_w = x_r.mean(), y_w.mean()

Sxy = np.sum((x_r - xbar_r) * (y_w - ybar_w))
Sxx = np.sum((x_r - xbar_r) ** 2)
pendiente_manual = Sxy / Sxx
intercepto_manual = ybar_w - pendiente_manual * xbar_r

print(f"pendiente manual = {pendiente_manual:.4f}")
print(f"intercepto manual = {intercepto_manual:.4f}")

reg = stats.linregress(x_r, y_w)
print(f"\nscipy.linregress -> slope={reg.slope:.4f}, intercept={reg.intercept:.4f}, "
      f"r={reg.rvalue:.4f}, p-value={reg.pvalue:.4g}")

print(f"\nEcuación: writing score = {intercepto_manual:.4f} + {pendiente_manual:.4f} x reading score")
```

```
pendiente manual = 0.9935
intercepto manual = -0.6676

scipy.linregress -> slope=0.9935, intercept=-0.6676, r=0.9546, p-value=0

Ecuación: writing score = -0.6676 + 0.9935 x reading score
```

In [9]:
```
# Predicción puntual: estudiante con reading score = 80
reading_ejemplo = 80
prediccion = intercepto_manual + pendiente_manual * reading_ejemplo
```

```
print(f"Predicción para reading score = {reading_ejemplo}: writing score = {prediccion:.2f}")

fig, ax = plt.subplots(figsize=(7, 5))
sns.scatterplot(data=df, x="reading score", y="writing score", alpha=0.3, ax=ax, label="Datos reales")
x_linea = np.linspace(df["reading score"].min(), df["reading score"].max(), 100)
ax.plot(x_linea, intercepto_manual + pendiente_manual * x_linea, color="red", linewidth=2,
        label="Recta de regresión")
ax.scatter([reading_ejemplo], [prediccion], color="black", zorder=5, s=80,
           label=f"Predicción (reading={reading_ejemplo})")
ax.set_title("Regresión lineal: writing score ~ reading score")
ax.legend()
plt.tight_layout()
plt.show()
```

```
Predicción para reading score = 80: writing score = 78.81
```




**Interpretación:**

- **Pendiente (0.9935):** por cada punto adicional en `reading score`, el `writing score` esperado sube, en promedio, casi 1 punto (0.9935).
- **Intercepto (-0.6676):** sería el `writing score` esperado si `reading score` = 0 — pero el mínimo real observado es 17, así que este valor no tiene una interpretación práctica directa (es solo el "anclaje" matemático de la recta).
- **Predicción:** un estudiante con `reading score` = 80 tendría un `writing score` esperado de **≈78.81**.

---

# Ejercicio 5 — Leer el coeficiente de determinación ($R^2$)

**Situación:** ¿qué tan bien predice el modelo del Ejercicio 4?

## Fórmula de $R^2$

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}} = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

Con un solo predictor, existe un atajo: $R^2 = r^2$.

In [10]:
```
y_pred = intercepto_manual + pendiente_manual * x_r

SS_res = np.sum((y_w - y_pred) ** 2)
SS_tot = np.sum((y_w - ybar_w) ** 2)
R2_manual = 1 - SS_res / SS_tot

print(f"SS_res = {SS_res:,.2f}")
print(f"SS_tot = {SS_tot:,.2f}")
print(f"R^2 (1 - SSres/SStot) = {R2_manual:.4f}")
print(f"R^2 (atajo: r^2 = {reg.rvalue:.4f}^2) = {reg.rvalue**2:.4f}")
```

```
SS_res = 20,470.86
SS_tot = 230,677.08
R^2 (1 - SSres/SStot) = 0.9113
R^2 (atajo: r^2 = 0.9546^2) = 0.9113
```

**Interpretación:** el modelo explica el **91.1%** de la variación de `writing score` a partir de `reading score` — un ajuste muy fuerte. El **8.9%** restante corresponde a otros factores no incluidos en el modelo (motivación, calidad de instrucción, variabilidad propia del examen, etc.).

---

# Ejercicio 6 — El riesgo de extrapolar

**Situación:** ¿qué pasa si usamos la recta del Ejercicio 4 fuera del rango de datos observado?

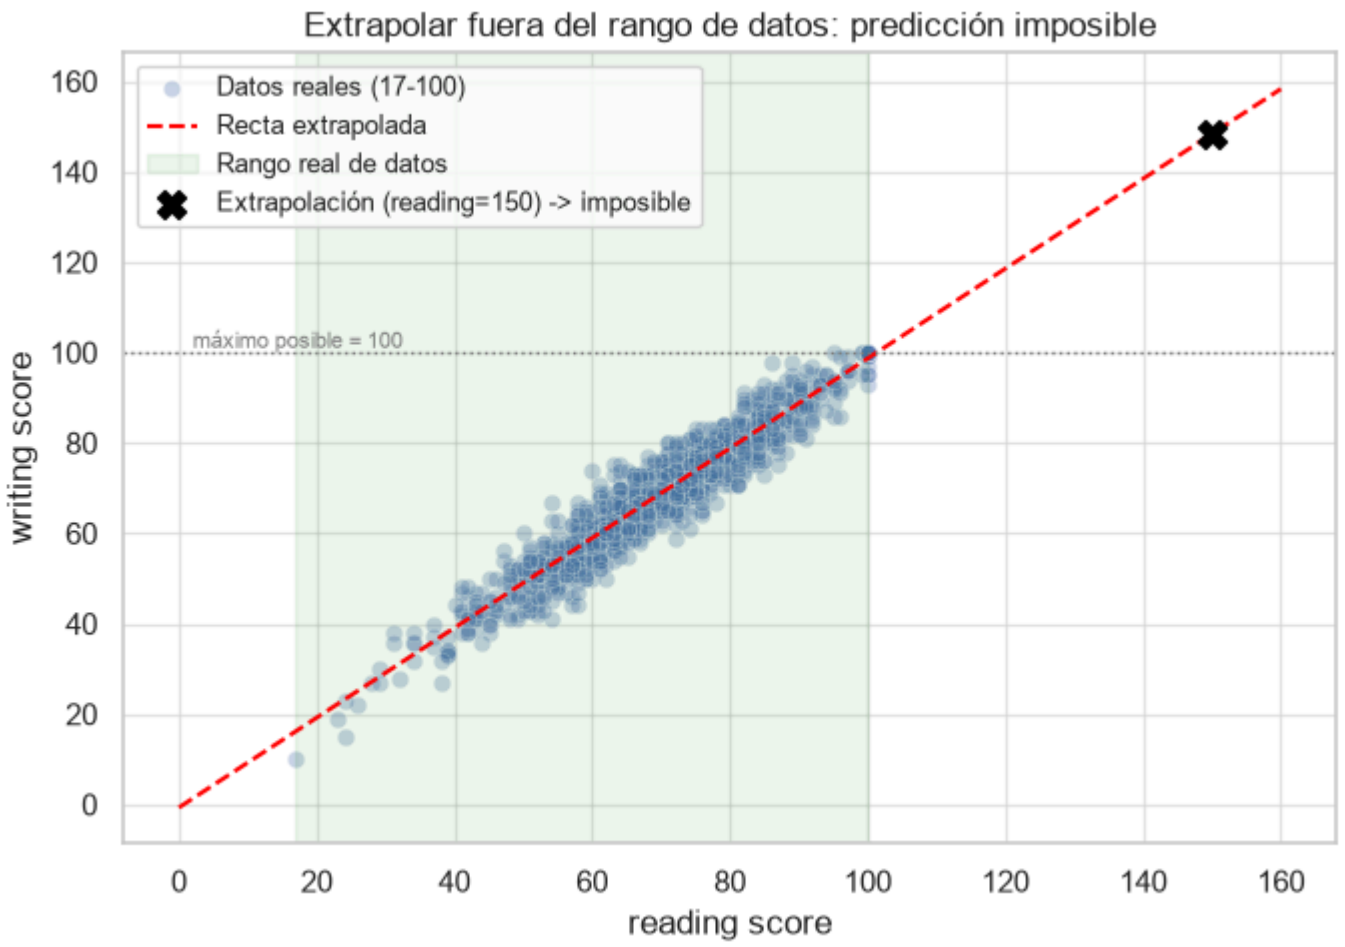
In [11]:
```
print(f"Rango real de reading score en el dataset: {df['reading score'].min()} a {df['reading score'].max()}")
print(f"Rango real de writing score en el dataset: {df['writing score'].min()} a {df['writing score'].max()}")

reading_extrapolado = 150   # fuera del rango real (max=100)
prediccion_extrapolada = intercepto_manual + pendiente_manual * reading_extrapolado
print(f"\nPredicción para reading score = {reading_extrapolado} (fuera de rango):"
      f" writing score = {prediccion_extrapolada:.2f}")
print("¡Un writing score de 148 es IMPOSIBLE! (el máximo real es 100)")
```

```
Rango real de reading score en el dataset: 17 a 100
Rango real de writing score en el dataset: 10 a 100

Predicción para reading score = 150 (fuera de rango): writing score = 148.36
¡Un writing score de 148 es IMPOSIBLE! (el máximo real es 100)
```

In [12]:
```
fig, ax = plt.subplots(figsize=(7, 5))
sns.scatterplot(data=df, x="reading score", y="writing score", alpha=0.3, ax=ax, label="Datos reales (17-100)")
x_linea_ext = np.linspace(0, 160, 100)
ax.plot(x_linea_ext, intercepto_manual + pendiente_manual * x_linea_ext, color="red", linewidth=1.5,
        linestyle="--", label="Recta extrapolada")
ax.axvspan(df["reading score"].min(), df["reading score"].max(), color="green", alpha=0.08,
           label="Rango real de datos")
ax.scatter([reading_extrapolado], [prediccion_extrapolada], color="black", zorder=5, s=100, marker="X",
           label=f"Extrapolación (reading={reading_extrapolado}) -> imposible")
ax.axhline(100, color="gray", linestyle=":", linewidth=1)
ax.text(2, 101, "máximo posible = 100", fontsize=8, color="gray")
ax.set_title("Extrapolar fuera del rango de datos: predicción imposible")
ax.legend(loc="upper left", fontsize=9)
plt.tight_layout()
plt.show()
```




**Interpretación:** la predicción (148.36) cae **fuera del rango posible** de `writing score` (0-100) — una señal inequívoca de que el modelo se está usando mal. La recta se ajustó **solo** con datos donde `reading score` va de 17 a 100; fuera de ese rango no hay ninguna garantía de que la relación siga siendo lineal. **Extrapolar** (predecir fuera del rango de los datos de entrenamiento) es uno de los errores más comunes al aplicar regresión lineal — la zona verde del gráfico es donde sí se puede confiar en el modelo.

---

## Bonus — ¿Cuánta muestra hubiera hecho falta? (análisis de potencia)

Como cierre, aplicamos el concepto de **tamaño de muestra óptimo** al Ejercicio 1: ¿cuántos estudiantes por grupo hubieran sido necesarios para detectar, con 80% de potencia, la diferencia real que encontramos en `writing score` entre hombres y mujeres?

$$n_{\text{por grupo}} = \frac{2(z_{\alpha/2} + z_{\beta})^2}{d^2}$$

In [13]:
```
d_writing = diferencia / np.sqrt(sp2)

z_alpha2 = stats.norm.ppf(1 - alpha / 2)
z_beta80 = stats.norm.ppf(0.80)

n_necesario_manual = 2 * (z_alpha2 + z_beta80) ** 2 / d_writing**2
print(f"Cohen's d (writing score, gender) = {d_writing:.3f}")
print(f"n necesario por grupo (80% potencia, aproximación normal) = {n_necesario_manual:.1f}")

try:
    from statsmodels.stats.power import TTestIndPower
    n_statsmodels = TTestIndPower().solve_power(effect_size=d_writing, alpha=alpha, power=0.80,
                                                alternative="two-sided")
    print(f"n necesario por grupo (80% potencia, statsmodels) = {n_statsmodels:.1f}")
except ImportError:
    print("(statsmodels no disponible en este entorno; se deja solo la aproximación manual)")

print(f"\nMuestra real usada: {n1} hombres, {n2} mujeres -> muchísima más potencia que la mínima necesaria.")
```

```
Cohen's d (writing score, gender) = 0.632
n necesario por grupo (80% potencia, aproximación normal) = 39.4
n necesario por grupo (80% potencia, statsmodels) = 40.3

Muestra real usada: 482 hombres, 518 mujeres -> muchísima más potencia que la mínima necesaria.
```

---

## Resumen: vocabulario que llevas a la Semana 7

| Término | Fórmula clave | En una frase |
| --- | --- | --- |
| Levene | $W$ sobre $Z_{ij} = \|X_{ij} - \tilde{X}_i\|$ | ¿Los grupos tienen la misma dispersión? |
| Prueba t | $t = \frac{\bar{x}_1 - \bar{x}_2}{SE}$ | ¿Las medias son distintas más allá del ruido esperado? |
| Correlación (r) | $r = \frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}}$ | Qué tan fuerte y en qué dirección se mueven dos variables juntas |
| Pendiente | $m = \frac{S_{xy}}{S_{xx}}$ | Cuánto cambia y por cada unidad de x |
| Intercepto | $b = \bar{y} - m\bar{x}$ | Valor de y cuando x=0 (a veces sin sentido práctico) |
| $R^2$ | $1 - \frac{SS_{res}}{SS_{tot}}$ | % de la variación de y que el modelo |

| Término | Fórmula clave | En una frase |
|---|---|---|
| | | logra explicar |
| Extrapolar | — | Usar el modelo fuera del rango de datos observado — riesgoso |
| Tamaño de muestra óptimo | $n = \frac{2(z_{\alpha/2} + z_{\beta})^2}{d^2}$ | Cuántos datos hacen falta para detectar un efecto con confianza |

**Material relacionado:** versión conceptual sin código — `Taller_01_Estadistica_inferencial.md` y su clave de respuestas `Taller_01_Estadistica_inferencial_profesor.md`.